

Evaluación de un mapa Auto-Organizado aplicado a una Interfaz Cerebro Computadora

Sergio Liberczuk , Antonio Quintero Rincón, Marcelo Risk, Instituto Tecnológico de Buenos Aires

Abstract—Brain Computer Interfaces allow communication with the environment and the control of physical devices to users with different neuromuscular disorders. These systems include signal acquisition, preprocessing and classification in order to determine what are the true intentions of the subject and thus generate an appropriate control signal. In the present work we evaluate the performance of a self-organized neural network depending on the number of training patterns. Obtained map is configured, labeled and used as a classifier in a Motor Imagery based Brain Computer Interface. The results are classification around 85 % when the map is trained with enough patterns. Based on a sensitivity analysis to each of the classes an optimal amount of training patterns is obtained of about 100 vectorial samples from which the classification rate does not increase substantially as instead it does the computational cost.

Resumen—Las interfaces cerebro computadora permiten la comunicación con el medio y el control de dispositivos físicos, a usuarios con diversas patologías musculares. Estos sistemas incluyen desde la adquisición de la señal con su preprocesamiento y hasta su clasificación, con el objetivo de determinar cuales son las verdaderas intenciones del usuario y generar en consecuencia una señal de control apropiada. En el presente trabajo se evalúa el desempeño de una red neuronal artificial de tipo Auto-Organizada, en función de la cantidad de patrones que se requieren para su entrenamiento. El mapa Auto-Organizado obtenido es configurado, rotulado y utilizado como clasificador en una Interface Cerebro Computadora basada en Imaginería Motora. Como resultado se obtuvieron tasas de clasificación del 85 % cuando el mapa es entrenado con una suficiente cantidad de patrones. A partir de un análisis de sensibilidad a cada una de las clases, se obtiene una cantidad óptima de patrones de entrenamiento de alrededor de 100 muestras vectoriales a partir de las cuales la tasa de clasificación no aumenta considerablemente, en cambio se incrementa el costo computacional asociado.

Index Terms—A Interfaces-Cerebro Computadora, Ingeniería en Rehabilitación, Mapas Auto-Organizados, Electroencefalograma.

I. INTRODUCTION

DESDE hace muchos años, diversos grupos de investigación han tratado de desarrollar sistemas que permitan una interacción directa entre el hombre y la computadora. Para tal fin, la actividad cerebral puede ser adquirida por medio de diversas tecnologías basadas en distintos principios físicos, ya sea por métodos invasivos o no-invasivos.

Estas señales son luego procesadas con el objetivo de generar una señal de control, capaz de operar algún dispositivo físico como podría ser una silla de ruedas, un brazo robótico o simplemente una computadora que ejecute comandos internos como abrir aplicaciones o deletrear texto. Este sistema se conoce como Interface Cerebro Computadora (BCI, *por sus siglas en inglés*) [1]. Las BCI constituyen un canal tanto de comunicación como de control que no utiliza las salidas

convencionales del cerebro como los nervios periféricos o los músculos [2] [3]. De este modo se contribuye a aumentar notablemente las posibilidades de comunicación y relación con el medio exterior en pacientes con severos cuadros de incapacidad motora.

Los primeros dispositivos se desarrollaron sobre la base del electroencefalograma (EEG) convencional, dado que éste no requiere de procesos quirúrgicos, ni de costosos implantes. Además posee muy buena resolución temporal del orden de los milisegundos, es decir, a la escala de los procesos cognitivos que se pretenden estudiar.

Como desventaja, el EEG carece de buena relación señal-ruido y tiene aún peor resolución espacial (en comparación con las técnicas invasivas). No obstante, el notable avance que se produjo en los últimos años en los métodos de aprendizaje maquina y procesamiento de señales [4], así como las nuevas tecnologías en electrodos secos dejan este enfoque como un abordaje bastante atractivo.

El sistema integral que comprende una BCI comienza con una etapa de adquisición de la señal a la que le sigue una etapa de preprocesamiento, filtrado o limpieza. Luego se realiza la extracción de características, éstas pueden pertenecer al dominio espacial, temporal, frecuencial o a una combinación de los mismos.

Luego le sigue la etapa de clasificación de las señales que asigna una clase o categoría a cada vector de características proveniente de la etapa anterior. Finalmente tenemos la retroalimentación con el usuario cerrando de esta forma el ciclo [5].

La imaginería motora consiste en el procedimiento de imaginar el movimiento de un miembro hacia la izquierda o hacia la derecha, al tiempo que se adquiere el EEG del sujeto, sin que este movimiento se produzca realmente.

Este proceso conocido como sincronización y desincronización relacionada a eventos (ERS/ERD) , genera una sincronización de las ondas μ y β en ciertos canales del EEG, aumentando su energía de modo que se puede identificar hacia que lado el sujeto esta imaginando el movimiento observando el espectro frecuencial de estas señales originadas en la corteza pre-motora [6].

El objetivo del presente trabajo es evaluar el desempeño de una red neuronal artificial de tipo Auto-Organizada (SOM), configurada y rotulada para ser utilizada posteriormente como clasificador en una BCI basada en imaginería motora.

II. MATERIALES Y MÉTODOS

A. Datos

Las señales de EEG analizadas en este trabajo fueron proporcionadas por el Departamento de Informática Médica del Instituto de Ingeniería Biomédica de la Universidad Tecnológica de Graz, Austria. Consisten en tres canales de EEG (C3, Cz y C4) que fueron adquiridos a 128 muestras por segundo utilizando un filtro pasa bandas de 0.5 a 30 muestras por segundo. Estos datos fueron tomados durante 280 pruebas de imaginación de los movimientos de las manos derecha e izquierda y fueron publicados en la "International Data Analysis Competition on Brain-Computer Interfaces (Data set III)" [7].

Cada prueba tiene una duración de 9 s, 3 s de preparación (periodo donde el sujeto sentado en posición relajada a 1 metro de distancia del monitor observa una flecha indicando hacia donde deberá realizar el movimiento), seguido por otros 6 s para realizar la tarea mental que corresponda.

Finalmente se tendrá un arreglo tridimensional de 3 canales por 1152 muestras temporales (9 seg x 128 muestras por segundo) por 280 intentos etiquetados (140 pruebas registradas durante la imaginación del movimiento de la mano izquierda y 140 pruebas registradas durante la imaginación del movimiento de la mano derecha).

Tanto para el entrenamiento como para la evaluación de los métodos, los datos fueron seleccionados aleatoriamente desde el total de las 280 pruebas.

Las probabilidades para cada clase fueron iguales tanto en la fase de entrenamiento como en la fase de evaluación.

B. Extracción de características

Densidad Espectral de Potencias. Se caracterizó la señal mediante un modelo Auto-Regresivo (AR):

$$x[n] = -\sum_{k=1}^p a_k x[n-k] + e[n] \quad (1)$$

donde $x[n]$ es la señal observada en el instante n , a_k son los coeficientes del modelo de orden p y $e[n]$ es ruido blanco.

La selección del orden es importante a la hora de determinar los coeficientes del modelo. Un orden muy bajo resultará en una pobre estimación de la densidad espectral de potencias (PSD), mientras que un orden muy alto puede conducir a picos espurios.

Ordenes desde 3 hasta 10 fueron probados para ver cual de ellos arrojaba mejores resultados en términos de tasas de clasificación.

Se calcularon para cada electrodo los coeficientes AR con el método de Yule-Walker [8], [9].

A partir del modelo AR se estimó la PSD en segmentos de señal de 3 segundos de duración (desde el segundo 4 al segundo 7). Se eligieron estos segmentos temporales dado que en ellos se encontró la mayor cantidad de información discriminable.

De esta manera se pueden obtener 4 valores correspondientes al contenido de energía en 4 bandas frecuenciales diferentes (1 a 4 Hz, 4 a 8 Hz, 8 a 13 Hz y 13 a 20Hz) por cada canal.

Debido a que el canal Cz presenta poca información que se pueda discriminar, se lo ha descartado para la clasificación.

Finalmente se han formado vectores característicos (VC) de 4 elementos, realizando el cociente entre los 4 valores de energía pertenecientes a C3 y los 4 valores de energía pertenecientes a C4, de manera que cada VC porta información de ambos canales.

El cociente entre los valores de energía realza las diferencias que existen entre ambos canales (C3 y C4) para cada banda de frecuencia.

C. Clasificación

Mapas Auto-Organizados. En este tipo de redes neuronales no se requiere conocimiento a priori de las clases a las que pertenecen las distintas muestras. Es una red que utiliza un aprendizaje no supervisado de tipo competitivo.

El SOM aprende a clasificar vectores de entrada de acuerdo a como éstos están agrupados en el propio espacio de entrada. Es decir que aprende tanto la distribución como la topología de las muestras.

Durante la etapa de entrenamiento, se le presenta a la red un conjunto de vectores de entrenamiento para que ésta establezca, en función de la semejanza entre los datos, las diferentes categorías a las que pertenecen dichos datos.

Una neurona se adapta a la activación de su vecina, generando una respuesta activa para entradas similares. Al final de este proceso se obtiene un mapa en el que entradas similares excitan o activan salidas similares.

Finalmente las neuronas se rotulan de acuerdo a la clase que más veces activa a cada neurona, para que luego en la fase de funcionamiento, dichas neuronas identifiquen a las clases que pertenecerán nuevos patrones de prueba nunca antes vistos por la red [10].

Además de la clasificación, una de las principales aplicaciones de las redes SOM es la visualización de datos multidimensionales. Esta clase de datos presenta dificultades a la hora de representarlos para su visualización. En este aspecto la utilización del SOM presenta ventajas dado que representan la distribución de las muestras en el espacio de entrada de una manera muy gráfica e intuitiva [11].

En este trabajo se implementó de una grilla bidimensional cuadrada de 7 neuronas (este parámetro se varía hasta encontrar el mínimo valor que diera buenas tasas de clasificación).

Se entrenó esta red presentándole 10 épocas (más épocas solo aumentan el costo computacional del algoritmo) de un lote de patrones de entrenamiento de cantidad variable extraídos en forma totalmente aleatoria del lote total de 280 muestras etiquetadas.

El parámetro de velocidad de entrenamiento de la red se varió desde 0.01 hasta 100 en ordenes de 10 dejando el valor ajustado en 1. La velocidad de entrenamiento se achica conforme avanza el proceso. El radio inicial de la vecindad se varió también desde 0.01 hasta 100 en ordenes de 10 dejando el valor ajustado en 1.

La función de vecindad que se utilizó es la que viene por defecto con el paquete de software que es la función gaussiana.

Para la implementación de los distintos algoritmos se utilizó MATLAB de MathWorks versión R2009b 7.9.0.529 y SOM Toolbox 2.0 [12].

III. RESULTADOS

Para el modelo AR el número de orden fue de 6, de acuerdo con el método de Yule-Walker.

En la figura 1 se puede observar el mapa Auto-Organizado obtenido una vez que éste ha sido entrenado y rotulado.




Figura 1. Esquema de la SOM donde se pueden apreciar dos clusters, correspondientes a las dos clases de datos.

En dicha figura se observa la formación de 2 clusters representativos de las 2 clases existentes en los datos. La clase representada con una 'o' corresponde a la tarea de imaginar el movimiento de la mano izquierda, mientras que la clase representada con '+' corresponde a la tarea de imaginar el movimiento de la mano derecha.

Los distintos parámetros de la red fueron configurados de manera totalmente empírica, buscando los valores mínimos que den una performance aceptable sin incrementar el costo computacional asociado.

El parámetro de mayor interés en el presente trabajo ha sido la dependencia con la cantidad de patrones de entrenamiento (#PE) de la red. #PE se varió en el rango que va desde 20 a 260 en saltos de 10 patrones. Para cada valor de la variable #PE se efectuaron 10 corridas. En cada una de las 10 corridas se extrajeron #PE patrones para el entrenamiento del total de 280 en forma aleatoria dejando, aleatoriamente también, 280-#PE patrones para prueba (#PT).

Con estos patrones de prueba (#PT) se calcula la tasa de clasificación. El resultado se puede observar en la figura 2 que muestra la evolución de la tasa de clasificación como función de #PE.

Se observa que a partir de aproximadamente 100 patrones de entrenamiento, la tasa de clasificación obtenida es del 83 % y cambia menos de 1 % por más que aumentemos #PE a más del doble.

También puede observarse que la varianza de las cajas va disminuyendo a medida que aumenta #PE.

Las tasas obtenidas se corroboraron mediante un esquema de validación cruzada conocido como "leave one out", donde se entrenaron 280 mapas de Kohonen, dejando fuera cada vez un patrón de prueba diferente y entrenando con los 279 restantes. Como resultado de los 280 mapas configurados se obtuvieron aciertos, es decir, el patrón de prueba que ha quedado fuera fue clasificado correctamente en 239 de ellos, lo que da una tasa de clasificación del 85 %.

Para cada cantidad de la variable #PE (promediado sobre la base de 10 corridas) se obtienen 4 valores correspondientes

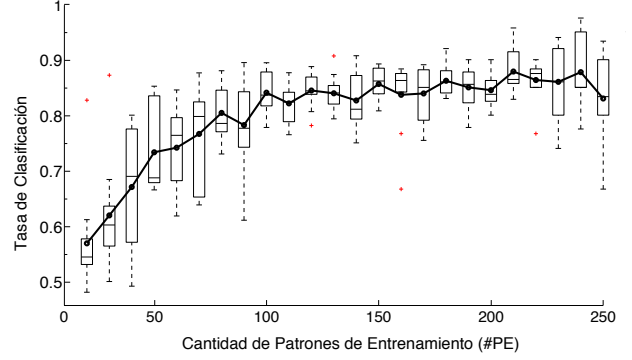


Figura 2. Gráfico de cajas de la tasa de clasificación en función de la cantidad de patrones de entrenamiento (#PE).

a Verdadera Izquierda (VI), Verdadera Derecha (VD), Falsa Izquierda (FI) y Falsa Derecha (FD).

A la primera categoría pertenecen los patrones etiquetados como Izquierda que verdaderamente fueron identificados como Izquierda por el sistema. A la segunda categoría pertenecen los patrones pertenecientes a la clase Derecha correctamente identificados como Derecha por nuestro mapa. A las otras dos categorías pertenecen los patrones que fueron identificados erróneamente como se deduce con la misma lógica.

Con estos 4 valores se construyen las matrices de confusión que se pueden observar en la Tabla I donde la diagonal (para cada cantidad de #PE) indica la cantidad absoluta de aciertos y los elementos fuera de la diagonal indican la cantidad de fallas del sistema.

De estas matrices se derivan los índices denominados factores de sensibilidad para cada clase (FSI y FSD) que se muestran en la figura 3. Estos índices fueron calculados según la siguientes fórmula:

$$FSI = \frac{VI}{VI+FI} \quad FSD = \frac{VD}{VD+FI} \quad (2)$$

FSI y FSD indican el grado de sensibilidad del sistema al reconocimiento de una clase en particular a medida que aumentamos la cantidad de patrones de entrenamiento. Como se puede observar de la figura la clase Derecha aumenta notablemente su sensibilidad, no así la otra clase que se mantiene cerca de su valor inicial disminuyendo como mucho un 20 %.

IV. DISCUSIÓN

En la figura 1 el cluster de la clase Derecha posee mayor tamaño que el cluster de la clase Izquierda, esto está directamente relacionado con la variabilidad que presenta esta clase por sobre la otra. Se cree que este hecho es un hallazgo particular de estos datos, propio de la forma en que se realizó el experimento o de las características del sujeto en cuestión pero no del paradigma de "Imaginería Motora" utilizado.

No obstante, es interesante hacer el mismo análisis en otros datos provenientes del mismo paradigma para revisar esta situación.

Tabla I
MATRICES DE CONFUSIÓN EN FUNCIÓN DE LA CANTIDAD DE PATRONES DE ENTRENAMIENTO. VALORES PROMEDIADOS SOBRE 10 CORRIDAS Y EXPRESADOS EN % DE #PT. (I)ZQUIERDA. (D)ERECHA

| # Patrones de entrenamiento | 20 | | 50 | | 80 | | 110 | | 140 | | 170 | | 200 | | 230 | |
|-----------------------------|----|----|----|----|----|----|-----|----|-----|----|-----|----|-----|----|-----|----|
| Clasificó como | I | D | I | D | I | D | I | D | I | D | I | D | I | D | I | D |
| Clase Original | | | | | | | | | | | | | | | | |
| I | 47 | 4 | 44 | 7 | 44 | 7 | 44 | 6 | 44 | 6 | 41 | 7 | 42 | 6 | 44 | 8 |
| D | 35 | 14 | 20 | 29 | 15 | 34 | 9 | 41 | 7 | 43 | 5 | 47 | 5 | 47 | 3 | 45 |




Figura 3. Factor de sensibilidad para la clase izquierda (FSI) y Factor de sensibilidad para la clase derecha (FSD) en función de la cantidad de patrones de entrenamiento (#PE).

Las tasas de clasificación calculadas, con un promedio de 85 % con picos de hasta 92 % en algunas configuraciones, son comparables con los resultados publicados en la competencia "BCI 2003 competition" [7].

Esto muestra que los mapas Auto-Organizados poseen performances similares a otros clasificadores ampliamente utilizados en la actualidad como pueden ser: máquinas de soporte vectorial (SVM), análisis de discriminante lineal (LDA), Naive Bayes u otros.

Pero los mapas Auto-Organizados tienen la ventaja adicional de permitir visualizar, de alguna forma, los patrones multidimensionales.

Del análisis de los datos surge que la tasas de clasificación se hacen asintóticas a estos valores aproximadamente a partir de 100 muestras de entrenamiento.

Con respecto a la figura 3 se deduce que el momento más temprano en que la tasa de clasificación alcanza este valor coincide con el momento en que FSD alcanza el 90 % de su valor máximo.

Esto sugiere la existencia de una clase limitante (con respecto a la otra) y está sin duda asociado a la mayor variabilidad que posee esta clase (Derecha, en este caso) por sobre la clase Izquierda (como se aprecia en la figura 1), dado que es razonable que se necesite una cantidad mínima de muestras de entrenamiento para representar más certeramente, la mayor variabilidad que posee la clase, en una resolución de grilla determinada. A mayor tamaño de grilla más aumenta este mínimo.

Este análisis permite obtener un valor de #PE óptimo para el cual el sistema encuentra tasas de clasificación aceptables sin incrementar el costo computacional en exceso.

Este valor puede hallarse donde las curvas de sensibilidad se cortan. Es decir donde la clase Derecha alcanza casi el 90 %

del valor total que podría alcanzar y la clase Izquierda no decae tanto tampoco. En este trabajo el valor óptimo calculado es de 100 patrones de entrenamiento.

V. TRABAJOS FUTUROS

Como trabajo futuro interesa el estudio de alguna métrica que sea función del tamaño de los cluster que se forman o de la distancia de un patrón al centro del cluster de cada clase.

Esto último con el objetivo de utilizar los mapas Auto-Organizados como prácticos visualizadores de la distribución en el espacio de características de los patrones de entrenamiento y poder así cuantificar la bondad de las características utilizadas, así como también la variabilidad que poseen las clases.

Esto permitirá establecer comparaciones entre diversos métodos de extracción de características complementando a la tasa de clasificación como métrica.

También restaría como fue mencionado anteriormente realizar el mismo análisis en otros set de datos provenientes del mismo paradigma (imaginería motora), para verificar si la característica de que una clase posea más variabilidad que la otra es algo intrínseco al paradigma en cuestión o simplemente es característica particular del registro de EEG utilizado en este estudio.

VI. CONCLUSIONES

En el presente trabajo se estudió la performance de un mapa Auto-Organizado como clasificador de señales de EEG para el desarrollo de una BCI no invasiva.

La tasa de clasificación obtenida de 85 % es comparable con otros algoritmos que utilizaron este mismo set de datos [13].

Estos resultados no permiten concluir si la mayor variabilidad asociada a una de las clases por sobre la otra se debe a algo intrínseco al propio paradigma utilizado, pero si permiten mediante un análisis de sensibilidad determinar un óptimo para la cantidad de patrones requeridos para el entrenamiento de la red neuronal equilibrando la obtención de una buena tasa de clasificación con un costo computacional aceptable.

AGRADECIMIENTOS

Los autores agradecen al Dr. Enrique Segura por las discusiones que aportaron a la realización del presente trabajo, y al Dr. Silvano Zanutto por sus correcciones. Los autores agradecen el financiamiento proveniente del Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET), Argentina.

REFERENCIAS

- [1] J. Dornhege, J. Millan, T. Hinterberger, D. McFarland, and K. Muller, *Toward Brain-Computer Interfacing*. MA: The MIT Press, 2007.
- [2] J. R. Wolpaw, N. Birbaumer, D. J. McFarland, G. Pfurtscheller, and T. M. Vaughan, "Brain-computer interfaces for communication and control," *Clinical Neurophysiology*, vol. 113, pp. 767–791, 2002.
- [3] M. van Gerven, J. Farquhar, R. Schaefer, R. Vlek, J. Geuze, A. Nijholt, N. Ramsey, P. Haselager, L. Vuurpijl, S. Gielen, and Desain, "The brain-computer interface cycle," *Journal of Neural Engineering*, vol. 6, p. 041001, 2009.
- [4] F. Lotte, M. Congedo, A. L'ecuyer, F. Lamarche, and B. Arnaldi, "A review of classification algorithms for EEG-based brain-computer interfaces," *Journal of Neural Engineering*, vol. 4, pp. R1–R13, 2007.
- [5] A. Nijholt and D. Tan, "Brain-computer interfacing for intelligent systems," *Intelligent Systems, IEEE*, vol. 23, no. 3, pp. 72–79, may-june 2008.
- [6] G. Pfurtscheller, "EEG event-related desynchronization ERD and synchronization ERS," *Electroencephalography and Clinical Neurophysiology*, vol. 103, p. 26, 1997.
- [7] B. Blankertz, K.-R. Muller, G. Curio, T. Vaughan, G. Schalk, J. Wolpaw, A. Schlogl, C. Neuper, G. Pfurtscheller, T. Hinterberger, M. Schroder, and N. Birbaumer, "The BCI competition 2003: progress and perspectives in detection and discrimination of eeg single trials," *Biomedical Engineering, IEEE Transactions on*, vol. 51, no. 6, pp. 1044–1051, june 2004.
- [8] G. Yule, "On a method of investigating periodicities in disturbed series, with special reference to wolfer's sunspot numbers," *Philosophical Transactions of the Royal Society of London*, vol. 226, pp. 267–298, 1927.
- [9] G. Walker, "On periodicity in series of related terms," *Proceedings of the Royal Society of London*, vol. 131, pp. 518–532, 1931.
- [10] T. Kohonen, "The self-organizing map," *Proceedings of the IEEE*, vol. 78, no. 9, pp. 1464–1480, sep 1990.
- [11] L. Bueno and J. L. Pons, "Un sistema de interfaz cerebro ordenador basado en redes neuronales auto-organizadas," *XXVIII Jornadas de Automática, 2007*, 2007.
- [12] J. Vesanto, J. Himberg, E. Alhoniemi, and J. Parkankangas, "Som toolbox for matlab 5. technical report a57," 2000.
- [13] F. D. Farfán and C. J. Felice, "Comparación de diferentes métodos para la clasificación de señales de eeg en interfases cerebro computadora," *XV Congreso Argentino de Bioingeniería*, 2005.